# Lab08

Matheus Rodrigues da Silva(259256)

```
library("reticulate")
py_require("polars")
py_require("matplotlib")
```

```
import polars as pl

tipos_basics = {
    'tconst': pl.Utf8,
    'titleType': pl.Utf8,
    'primaryTitle': pl.Utf8,
    'originalTitle': pl.Utf8,
    'isAdult': pl.Int64,
    'startYear': pl.Int64,
    'endYear': pl.Int64,
    'runtimeMinutes': pl.Int64,
    'genres': pl.Utf8,
}

tipos_ratings = {
    'tconst': pl.Utf8,
    'averageRating': pl.Float64,
    'numVotes': pl.Int64,
}

tipos_principals = {
    'tconst': pl.Utf8,
    'nconst': pl.Utf8,
    'category': pl.Utf8,
    'job': pl.Utf8,
    'characters': pl.Utf8,
}
```

```
basics = pl.read_csv("data/title.basics0.tsv", separator="\t",
                     schema_overrides=tipos_basics,
                     null_values="\\N", quote_char=None)

ratings = pl.read_csv("data/title.ratings.tsv", separator="\t",
                      schema_overrides=tipos_ratings,
                      null_values="\\N", quote_char=None)

principals = pl.read_csv("data/title.principals0.tsv", separator="\t",
                         schema_overrides=tipos_principals,
                         null_values="\\N", quote_char=None)

filmes = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
)
```

1. Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
top5 = (
    filmes
    .sort(["averageRating", "numVotes", "tconst"], descending=[True, True, False])
    .select("tconst", "primaryTitle", "averageRating", "numVotes")
    .head(5)
)
print(top5)
```

```
shape: (5, 4)

 tconst      primaryTitle               averageRating  numVotes
 ---         ---                        ---            ---
 str         str                        f64            i64

 tt33075815  Kaveri                     10.0           1023
 tt27815015  Kurukku                    10.0           451
 tt28450376  Jedal Dar Omghe 30 Metri   10.0           142
 tt27859713  Sargashte                  10.0           134
 tt33507675  Gorgeous Rascal            10.0           115
```

7. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
generos = (
    filmes
    .filter(pl.col("averageRating") > 8)
    .select(pl.col("genres").str.split(",").alias("genero"))
    .explode("genero")
    .drop_nulls("genero")
    .group_by("genero")
    .agg(pl.len().alias("numero_filmes"))
    .sort("numero_filmes", descending = True)
)
print(generos.head(1))
```

```
shape: (1, 2)

 genero        numero_filmes
 ---           ---
 str           u32

 Documentary   10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
filmes_bons = filmes.filter(pl.col("averageRating") > 7.5).select("tconst")

top3_atores = (
    principals
    .lazy()
    .select("tconst", "nconst", "category")
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .join(filmes_bons.lazy(), on="tconst", how="semi")
    .unique(subset=["tconst", "nconst"])
    .group_by("nconst")
    .agg(pl.len().alias("numero_filmes"))
    .sort(["numero_filmes", "nconst"], descending=[True, False])
    .head(3)
    .collect()
)
print(top3_atores)
```

```
shape: (3, 2)

 nconst      numero_filmes
 ---         ---
 str         u32

 nm0004660   199
 nm0595934   155
 nm3183374   124
```

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-15 07:57:30 -03"
```