Lab09

AUTHOR
Matheus Rodrigues da Silva (259256)

```
library(reticulate)
py_require(c("plotnine", "pandas", "polars", "pyarrow"))
repl_python()
```

```
Python 3.13.16 (C:/Users/Matheus/AppData/Local/R/cache/R/reticulate/uv/cache/archive-
v0/7ze7HPmzS2YItBH1/Scripts/python.exe)
Reticulate 1.47.0 REPL -- A Python interpreter in R.
Enter 'exit' or 'quit' to exit the REPL and return to R.

exit
```

1. Importe o conjunto de dados diamonds, cujo arquivo está disponível no website da disciplina.

```
import polars as pl
from plotnine import *

diamonds = pl.read_csv("data/diamonds.csv")

print(diamonds.shape)
```

```
(53940, 10)
```

```
print(diamonds.head())
```

```
shape: (5, 10)
```

carat	cut	color	clarity	…	price	x	y	z
f64	str	str	str		i64	f64	f64	f64
0.23	Ideal	E	SI2	…	326	3.95	3.98	2.43
0.21	Premium	E	SI1	…	326	3.89	3.84	2.31
0.23	Good	E	VS1	…	327	4.05	4.07	2.31
0.29	Premium	I	VS2	…	334	4.2	4.23	2.63
0.31	Good	J	SI2	…	335	4.34	4.35	2.75

```
print(diamonds.schema)
```

```
Schema({'carat': Float64, 'cut': String, 'color': String, 'clarity': String, 'depth': Float64,
'table': Float64, 'price': Int64, 'x': Float64, 'y': Float64, 'z': Float64})
```

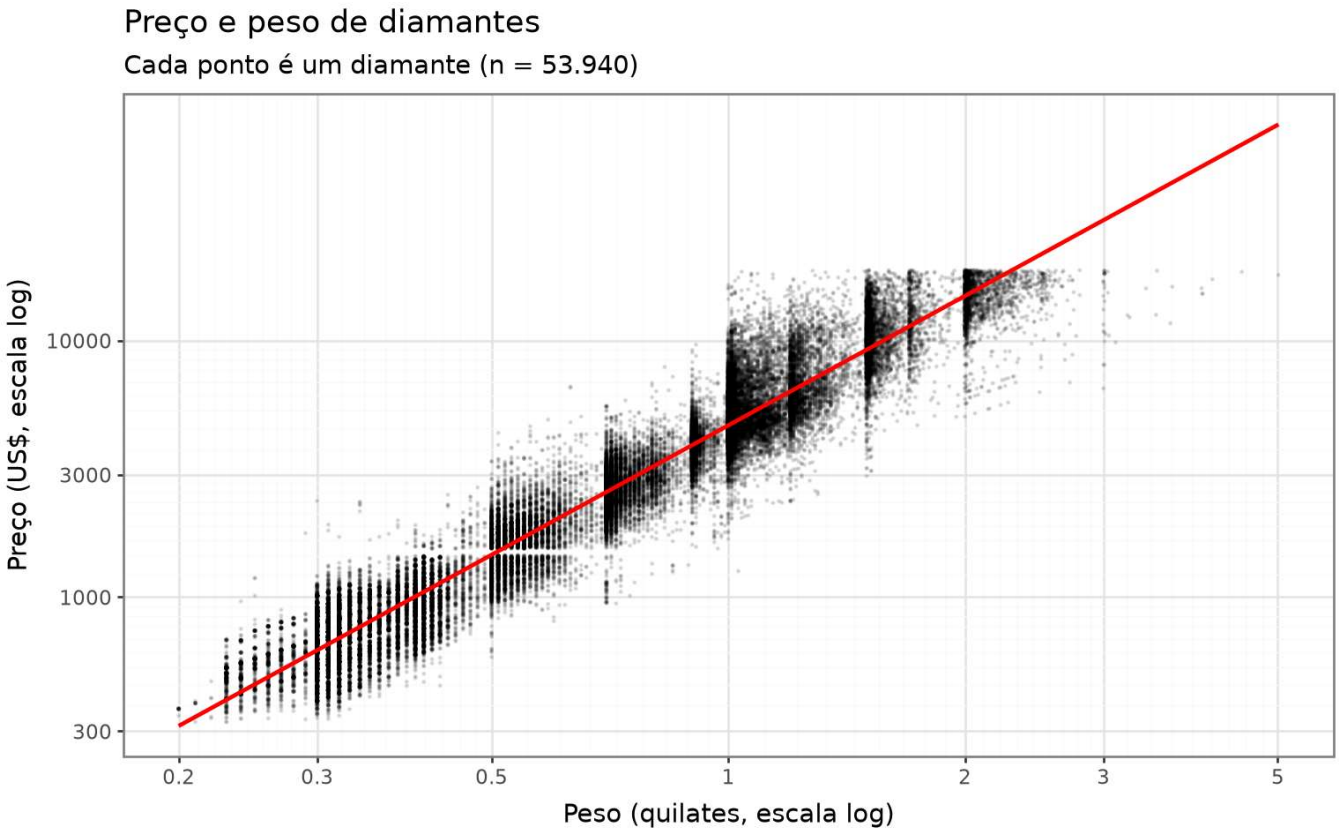
2. Crie uma visualização de dados que descreva a associação existente entre as variáveis peso (carat) e preço (price). Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

```
import polars as pl
from plotnine import *

print(diamonds.select(
    pl.corr("carat", "price").alias("r_original"),
    pl.corr(pl.col("carat").log(), pl.col("price").log()).alias("r_log_log")
))
```

```
shape: (1, 2)
┌────────────┬────────────┐
│ r_original ┆ r_log_log  │
│ ---        ┆ ---        │
│ f64        ┆ f64        │
╞════════════╪════════════╡
│ 0.921591   ┆ 0.965914   │
└────────────┴────────────┘
```

```
grafico = (
    ggplot(diamonds.to_pandas(), aes(x="carat", y="price"))
    + geom_point(alpha=0.1, size=0.1)
    + geom_smooth(method="lm", color="red", size=1)
    + scale_x_log10(breaks=[0.2, 0.3, 0.5, 1, 2, 3, 5])
    + scale_y_log10(breaks=[300, 1000, 3000, 10000])
    + labs(
        x="Peso (quilates, escala log)",
        y="Preço (US$, escala log)",
        title="Preço e peso de diamantes",
        subtitle="Cada ponto é um diamante (n = 53.940)"
    )
    + theme_bw()
    + theme(figure_size=(8, 5))
)
grafico.draw(show=True)
```



Na escala original, a relação é não linear e a variabilidade do preço aumenta com o peso, ou seja, diamantes de mesmo tamanho podem ter preços diferentes, e a diferença é maior entre os mais pesados. Aplicando a escala logarítmica, a relação se torna aproximadamente linear, o que sugere que o preço cresce de forma mais do que proporcional ao peso. Também se nota que os pontos se concentram em pesos com valores "redondos", como 0,5, 1 e 2 quilates, indicando que a oferta e a precificação se agrupam nesses valores. Como a dispersão em torno da tendência persiste, outras características, como corte, cor e clareza, provavelmente explicam parte da variação do preço.

3. A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo.

```
import pandas as pd
import polars as pl
from plotnine import *

ordem = ["Fair", "Good", "Very Good", "Premium", "Ideal"]

# Resumo numérico por corte (apoia o texto): correlação e inclinação da reta
resumo = (
    diamonds
    .group_by("cut")
    .agg(
        pl.len().alias("n"),
        pl.col("carat").mean().alias("carat_medio"),
        pl.corr("carat", "price").alias("r"),
        (pl.cov("carat", "price") / pl.col("carat").var()).alias("inclinacao"),
    )
    .with_columns(pl.col("cut").replace_strict({c: i for i, c in enumerate(ordem)}).alias("ord"
    .sort("ord")
```

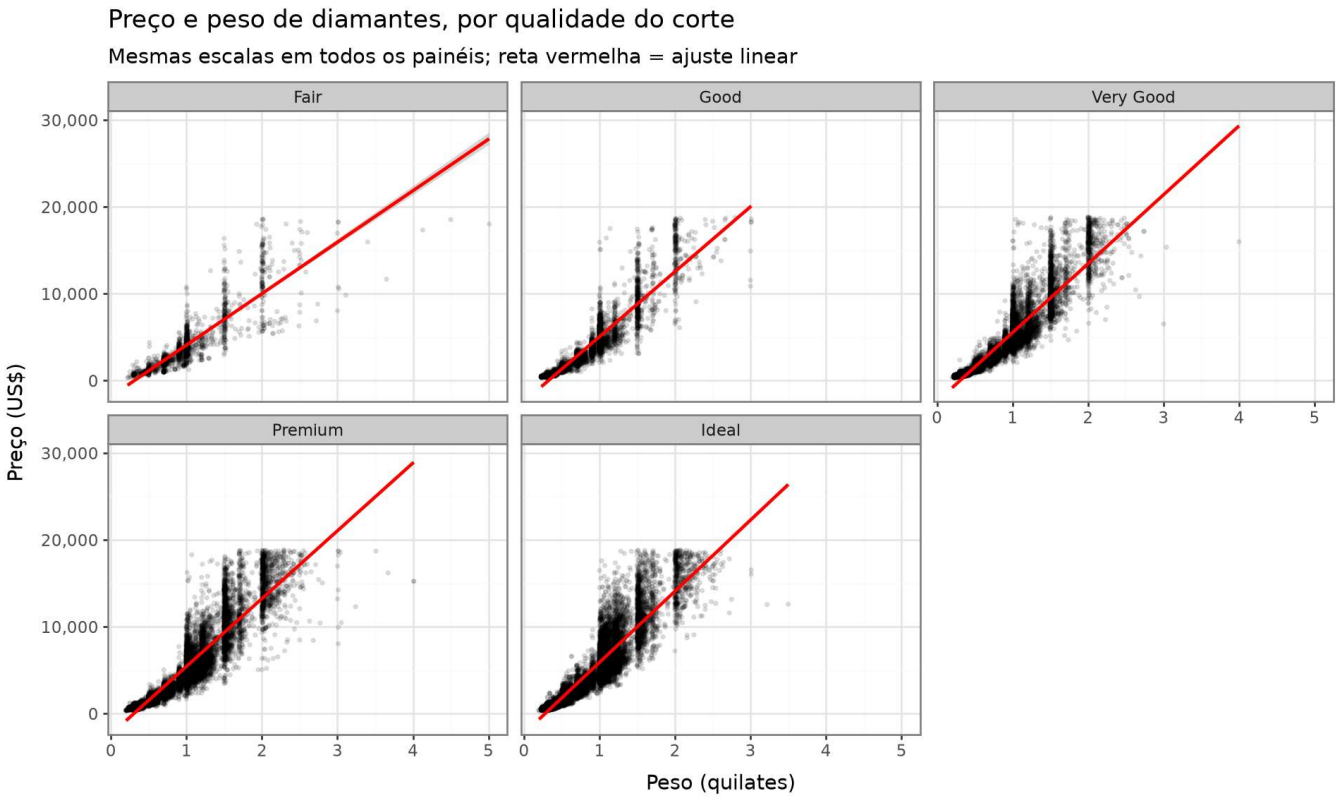
```
    .drop("ord")
)
print(resumo)
```

shape: (5, 5)

cut	n	carat_medio	r	inclinacao
str	u32	f64	f64	f64
Fair	1610	1.046137	0.859299	5924.495106
Good	4906	0.849185	0.922472	7479.636303
Very Good	12082	0.806381	0.92637	7935.971965
Premium	13791	0.891955	0.925005	7807.752032
Ideal	21551	0.702837	0.931176	8192.391304

```
# Cortes na ordem de qualidade (do pior ao melhor)
d = diamonds.to_pandas()
d["cut"] = pd.Categorical(d["cut"], categories=ordem, ordered=True)

grafico2 = (
    ggplot(d, aes(x="carat", y="price"))
    + geom_point(alpha=0.1, size=0.6)
    + geom_smooth(method="lm", color="red", size=1)
    + facet_wrap("~cut", ncol=3)
    + scale_y_continuous(labels=lambda l: [f"{v:,.0f}" for v in l])
    + labs(
        x="Peso (quilates)",
        y="Preço (US$)",
        title="Preço e peso de diamantes, por qualidade do corte",
        subtitle="Mesmas escalas em todos os painéis; reta vermelha = ajuste linear"
    )
    + theme_bw()
    + theme(figure_size=(10, 6))
)
grafico2.draw(show=True)
```



A relação observada na questão anterior se mantém em todos os cortes: em cada um deles, diamantes mais pesados são mais caros, com correlação positiva e forte. Há, porém, diferenças na intensidade dessa relação. A inclinação da reta varia de cerca de 5924.50 dólares por quilate adicional no corte Fair até 8192.39 no corte Ideal, e a dispersão em torno da tendência também muda entre os painéis. Isso indica que o corte modifica o quanto o preço aumenta com o peso, e não apenas o nível de preço. Também se nota que os cortes diferem na distribuição de pesos: os diamantes de corte Fair são, em média, mais pesados do que os de corte Ideal, o que ajuda a explicar por que o corte, isoladamente, não ordena os preços como se poderia esperar. Em resumo, a associação positiva entre peso e preço é geral, mas sua magnitude depende do corte.

4. Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
import pandas as pd
from plotnine import *

ordem_cut     = ["Fair", "Good", "Very Good", "Premium", "Ideal"]
ordem_color   = ["D", "E", "F", "G", "H", "I", "J"]
ordem_clarity = ["I1", "SI2", "SI1", "VS2", "VS1", "VVS2", "VVS1", "IF"]

d = diamonds.to_pandas() if hasattr(diamonds, "to_pandas") else diamonds.copy()
d["cut"]     = pd.Categorical(d["cut"],     categories=ordem_cut,     ordered=True)
d["color"]   = pd.Categorical(d["color"],   categories=ordem_color,   ordered=True)
d["clarity"] = pd.Categorical(d["clarity"], categories=ordem_clarity, ordered=True)

# Tamanho de cada combinação (corte, cor, clareza)
tam = d.groupby(["cut", "color", "clarity"], observed=True).size()
print(tam.describe())
```

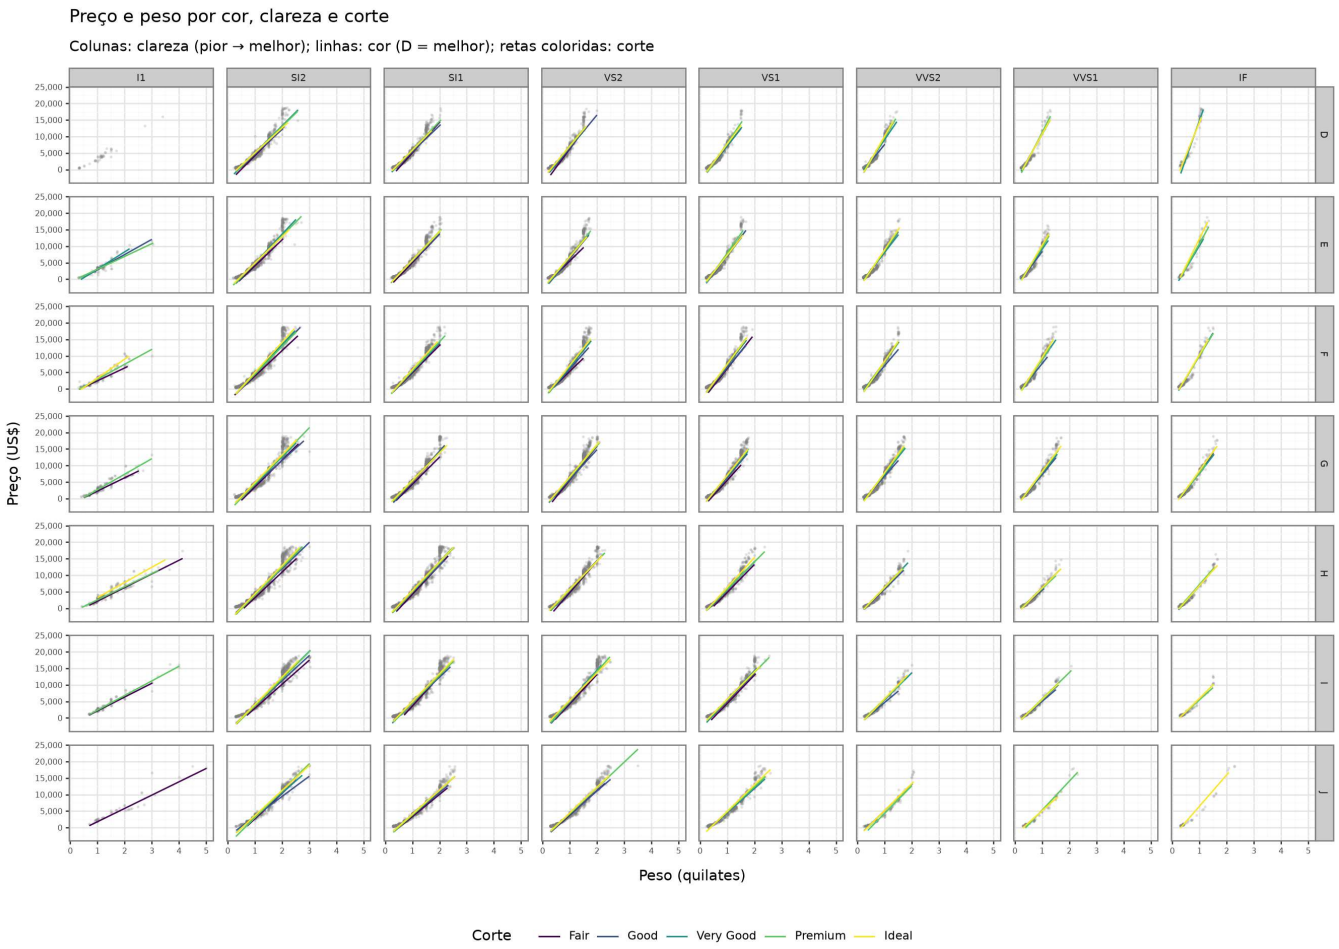
```
count     276.000000
mean      195.434783
std       223.106284
min         1.000000
25%        25.750000
50%        90.500000
75%       303.750000
max      1136.000000
dtype: float64
```

```
print("Combinações com menos de 20 diamantes:", (tam < 20).sum(), "de", len(tam))
```

```
Combinações com menos de 20 diamantes: 55 de 276
```

```
# Só ajusta reta onde há pelo menos 20 diamantes (reta com poucos pontos engana)
d["n_comb"] = d.groupby(["cut", "color", "clarity"], observed=True)["carat"].transform("size")
d_linhas = d[d["n_comb"] >= 20]

grafico3 = (
    ggplot(d, aes(x="carat", y="price"))
    + geom_point(color="grey", alpha=0.15, size=0.3)
    + geom_smooth(aes(color="cut"), data=d_linhas, method="lm", se=False, size=0.6)
    + facet_grid("color ~ clarity")
    + scale_y_continuous(labels=lambda l: [f"{v:,.0f}" for v in l])
    + labs(
        x="Peso (quilates)",
        y="Preço (US$)",
        color="Corte",
        title="Preço e peso por cor, clareza e corte",
        subtitle="Colunas: clareza (pior → melhor); linhas: cor (D = melhor); retas coloridas:
    )
    + theme_bw()
    + theme(figure_size=(14, 10), axis_text=element_text(size=6),
            strip_text=element_text(size=7), legend_position="bottom")
)
grafico3.draw(show=True)
```




```
# Inclinação (US$ por quilate) em cada combinação com n >= 20, para apoiar o texto
def incl(g):
    return g["carat"].cov(g["price"]) / g["carat"].var()

inclinacoes = d_linhas.groupby(["cut", "color", "clarity"], observed=True).apply(incl)
print(inclinacoes.describe())
```

```
count      221.000000
mean      9178.208455
std       2488.779651
min       3870.730979
25%       8022.167095
50%       8688.607418
75%      10200.728940
max      23347.952143
dtype: float64
```

Das dificuldades temos o número alto de combinações em que foi preciso escolher o que vai nos painéis (cor e clareza) e o que vai nas cores das retas (corte). As combinações com poucas observações que se torna instável, as sobreposições de pontos e leitura da figura também são outras dificuldades.

Observando a figura vemos que o peso é o principal fator associado ao preço, entretanto a taxa com que o preço aumenta depende da qualidade do diamante. A inclinação da reta varia bastante entre as combinações e as retas dos diferentes cortes dentro de um mesmo painel se separam, o que indica que o corte tem algum efeito adicional quando cor e clareza são fixadas. Já a clareza e a cor parecem

que os diamantes de melhor clareza têm retas mais inclinadas, isto é, o preço cresce mais rápido com o peso. Além disso, nas combinações raras, com poucos diamantes, as retas não são confiáveis e não permitem conclusões firmes.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-22 00:05:47 -03"
```